

Phân tích quan điểm phản hồi sinh viên tiếng Việt trên tập dữ liệu UIT-VSFC

Vũ Nguyên Đan – 23020351

Hà Xuân Huy – 23020375

Hoàng Mạnh Hùng – 23020371

Viện Trí tuệ Nhân tạo – Trường Đại học Công nghệ (UET-VNU)

Môn học: Xử lý ngôn ngữ tự nhiên

Giảng viên hướng dẫn: PGS.TS. Nguyễn Phương Thái

Nội dung trình bày

- Tổng quan dự án & Bài toán
- Phân tích dữ liệu (UIT-VSFC)
- Phương pháp đề xuất (PhoBERT Large)
- Thực nghiệm & Kết quả
- Phân tích & Đánh giá
- Kết luận & Hướng phát triển

Tổng quan & Đặt vấn đề

- Bối cảnh: Việc phân tích phản hồi sinh viên thủ công tốn kém thời gian và dễ sai sót.
- Mục tiêu: Xây dựng hệ thống tự động phân loại cảm xúc phản hồi (Sentiment Analysis) sử dụng Deep Learning.
- Input: Câu phản hồi tiếng Việt (Ví dụ: “Giảng viên dạy nhiệt tình”).
- Output: 3 nhãn cảm xúc:
 - Tiêu cực (Negative)
 - Trung tính (Neutral)
 - Tích cực (Positive)
- Thách thức chính:
 - Ngôn ngữ “teencode”, viết tắt, icon.
 - Dữ liệu mất cân bằng (Imbalanced Data).
 - Đặc trưng ngôn ngữ tiếng Việt (từ ghép, phủ định).

Bộ dữ liệu UIT-VSFC

- Nguồn: Khảo sát sinh viên đại học (Nguyen et al., 2018).
- Kích thước: > 16,000 câu.
- Phân chia dữ liệu:
 - Train (70%) – Dev (10%) – Test (20%).
- Chiến lược nhóm: Gộp Train + Dev để huấn luyện tối ưu.
- Đặc điểm phân bố:
 - Tích cực & Tiêu cực: Chiếm đa số (~95%).
 - Trung tính: Rất ít (~5%) → Thách thức lớn nhất.

Phương pháp đề xuất – Mô hình

- Mô hình: PhoBERT Large (Pre-trained Language Model).
- Lý do lựa chọn:
 - State-of-the-art cho tiếng Việt (huấn luyện trên 20GB văn bản).
 - Kiến trúc Transformer với cơ chế Attention hiểu ngữ cảnh tốt hơn n-gram/LSTM.
 - Phiên bản Large (370M tham số) trích xuất đặc trưng sâu hơn bản Base.
- Cơ chế: Input Token → BERT Encoder → [CLS] Token → Classifier (Linear).

Điểm mới – Tiền xử lý ngữ nghĩa (Semantic Preprocessing)

- Vấn đề: Dữ liệu chứa nhiều icon dạng text (colonlove, colonsmile) mang cảm xúc mạnh. Nếu xóa bỏ → mất thông tin.
- Giải pháp: Xây dựng từ điển ánh xạ (Mapping Dictionary) sang ngôn ngữ tự nhiên.
- Ví dụ:
 - colonlove → “yêu thích” (Tăng trọng số Positive).
 - colonsad → “buồn” (Tăng trọng số Negative).
 - wzjwz... → “giảng viên”.
- Hiệu quả: Giúp PhoBERT “hiểu” được cảm xúc của các ký tự đặc biệt.

```
def preprocess_line(line):  
    # Regex replacements  
    line = re.sub(r"wzjwz\d+", "giảng viên", line)  
    line = line.replace("doubledot", ":")  
    line = line.replace("colonlove", "yêu thích")  
    line = line.replace("colonsmile", "vui vẻ")  
    line = line.replace("colonsad", "buồn")  
    line = line.replace("colonp", ":p")  
    line = line.replace("colonb", ":b")  
    line = line.replace("colond", ":d")  
    line = line.replace("colonright", ")")  
    line = line.replace("colonleft", "(")  
    return line
```

Chiến lược huấn luyện (Training Strategy)

- Tối ưu hóa phần cứng:
 - Mixed Precision (FP16): Giảm VRAM, tăng tốc độ train.
 - Gradient Accumulation: Batch size ảo = 16 (giải quyết giới hạn bộ nhớ GPU).
- Hyperparameters:
 - Learning Rate: 1.5×10^{-5}
 - Epochs: 5
 - Scheduler: Linear Warmup (500 steps).

Kết quả thực nghiệm (Trên tập Test)

Bảng 1: Kết quả chi tiết theo từng lớp (Class-wise Metrics)

Lớp (Class)	Precision	Recall	F1-Score	Support
Negative	0.942	0.958	0.950	1,409
Neutral	0.681	0.551	0.609	167
Positive	0.951	0.956	0.954	1,590
Accuracy			0.936	3,166
Weighted Avg	0.933	0.936	0.934	3,166
Macro Avg	0.858	0.822	0.838	3,166

- Độ chính xác (Accuracy): 93.6%.
- Weighted F1-Score: 0.934.
- Kết quả từng lớp:
 - Negative: F1 0.950 (Rất cao).
 - Positive: F1 0.954 (Rất cao).
 - Neutral: F1 0.609 (Thấp hơn do thiếu dữ liệu).

So sánh với Baseline (Điểm nhấn)

Bảng 2: So sánh kết quả với baseline từ bài báo gốc

Phương pháp	Accuracy (%)	Average F1 (%)
Naive Bayes (baseline)	86.1	-
MaxEnt (baseline)	87.9	87.94
PhoBERT Large (đề xuất)	93.6	93.4


Bảng 3: So sánh chi tiết F1-Score theo từng lớp

Lớp	MaxEnt (baseline)	PhoBERT Large	Cải thiện
Positive	91.32%	95.4%	+4.08%
Negative	90.52%	95.0%	+4.48%
Neutral	33.99%	60.9%	+26.91%
Average	87.94%	93.4%	+5.46%

→ Kết luận: Deep Learning vượt trội hoàn toàn, đặc biệt khả năng nhận diện lớp khó (Neutral) tăng gấp đôi hiệu năng.

Phân tích lỗi (Confusion Matrix)

- **Ưu điểm:** Phân biệt cực tốt giữa Tích cực và Tiêu cực (nhầm lẫn rất ít).
- **Hạn chế:** Lớp Neutral thường bị nhầm sang Positive/Negative.
- **Nguyên nhân:**
 - Mất cân bằng dữ liệu: Neutral chỉ chiếm 5.2% tập Test.
 - Tính nhập nhằng: “Thầy nhiệt tình nhưng...” → bắt từ “nhiệt tình” → Positive.



Tổng kết các điểm sáng tạo

- Tiền xử lý thông minh: Chuyển đổi emoji/teencode thay vì loại bỏ.
- Chiến lược dữ liệu: Gộp Train + Dev để tối đa hóa lượng mẫu huấn luyện.
- Phát hiện sâu: Sai lớp Neutral chủ yếu do bản chất dữ liệu, không chỉ do mô hình.

Kết luận & Hướng phát triển

Kết luận:

- Đã xây dựng thành công mô hình đạt độ chính xác 93.6%.
- Hoàn toàn đáp ứng tốt nhu cầu thực tế (lọc phản hồi Khen/Chê).

Hướng phát triển:

- Data Augmentation cho lớp Neutral.
- Weighted Loss / Focal Loss.
- Ensemble: Kết hợp nhiều mô hình để tăng độ ổn định.